

Optimización del uso de Combustible en Maniobras Orbitales Sur del TKSAT-1 Usando Machine Learning

Ing. Rodrigo Montaña Villarroel, Postulante a Maestría en Sistemas Mecatrónicos

Resumen — Este artículo presenta los resultados de la optimización de los parámetros de maniobras de corrección orbital Sur en el satélite boliviano TKSAT-1. A partir de una base de datos detallada se las maniobras realizadas en los últimos 10 años, se optimizó la selección de parámetros clave, como los diferenciales de velocidad ($\Delta V_r, \Delta V_t, \Delta V_n$), con énfasis en la reducción del consumo de combustible y del ΔV_n .

El uso de modelos de Machine Learning permitió una optimización significativa en los parámetros de las maniobras de corrección Sur. Se desarrollaron y compararon dos modelos: una Red Neuronal Recurrente (RNN) con LSTM y un modelo de Random Forest. El modelo RNN LSTM logró reducir el consumo de combustible en un 8.82 %, manteniéndose dentro de los límites de control del ángulo de inclinación de la órbita. Por otro lado, el modelo Random Forest alcanzó una reducción superior del 23.53 %; sin embargo, su comportamiento excede los límites de control del ángulo de inclinación, lo que podría comprometer la estabilidad de la órbita.

Los resultados demuestran que la implementación de técnicas de Machine Learning en la gestión de recursos de satélites geoestacionarios no solo es factible, sino que también tiene un impacto significativo en términos de sostenibilidad operativa y retorno de inversión.

Palabras clave — Maniobras de Corrección Orbital, Órbitas Geoestacionarias, Machine Learning, RNN-LSTM, Random Forest, Optimización de Combustible, AOCS.

Línea de investigación — Automatización y Robótica.

I. INTRODUCCIÓN

Los satélites geoestacionarios desempeñan un papel fundamental en la prestación de servicios de telecomunicaciones [1], transmisión de televisión e Internet, permitiendo la conectividad de regiones remotas y contribuyendo al desarrollo de la infraestructura digital. La vida útil de estos satélites está directamente relacionada con la cantidad de combustible disponible a bordo, el cual se utiliza principalmente para compensar las diferentes perturbaciones a las cuales está sometido el satélite como fuerzas de atracción gravitacional de la tierra [2], luna y sol [3], Radiación de presión solar [4]. en las maniobras de corrección orbital [5]. De estas maniobras, la corrección Sur se considera crítica, ya que está destinada a controlar la inclinación orbital, garantizando que el satélite permanezca alineado con el plano ecuatorial.

El satélite boliviano TKSAT-1, entra en operación desde 2014, y desde entonces ha ejecutado maniobras de corrección de inclinación de forma periódica para mantener su órbita geoestacionaria.

Las metodologías tradicionales de corrección orbital se basan en cálculos predeterminados de los diferenciales de velocidad (ΔV) requeridos para ajustar la órbita del satélite. Sin embargo, estas metodologías no aprovechan la gran cantidad de datos históricos de maniobras anteriores, los cuales podrían emplearse para predecir parámetros óptimos para futuras maniobras. La falta de una estrategia que utilice información histórica y algoritmos de aprendizaje predictivo ha llevado a la exploración de técnicas de Machine Learning para abordar esta necesidad.

Este artículo tiene como objetivo optimizar el consumo de combustible en las maniobras de corrección orbital Sur del satélite TKSAT-1 mediante el uso de modelos de Machine Learning. Para ello, se emplearon dos técnicas de aprendizaje automático: Redes Neuronales Recurrentes con LSTM (RNN-LSTM) [6] y Random Forest [7]. Estos modelos predicen los parámetros óptimos de la maniobra (particularmente los valores de ΔV) con base en los registros de maniobras anteriores y con el objetivo de reducir el consumo de combustible, garantizando al mismo tiempo el control de la inclinación.

II. MATERIALES Y MÉTODOS

El proyecto sigue una metodología basada en el análisis de datos históricos de las maniobras de corrección orbital de los últimos 10 años del satélite TKSAT1 por lo que el desarrollo del proyecto seguirá las siguientes fases:

A. Recopilación y análisis de datos históricos

El centro de control satelital de la Agencia Boliviana Espacial desde el inicio de operación de la Agencia Boliviana Espacial lleva registros e informes de todos los procedimientos involucrados con el control de corrección orbital TKSAT-1, adicionalmente se lleva el registro de gasto de combustible ya que aparte de las maniobras el satélite también genera pulsos automáticos para el sistema de control de órbita y actitud (AOCS).

Maneuver Date and Time (T0): Este dato se refiere a la fecha y hora del tiempo cero de la maniobra, es decir el momento que se generara el primer pulso de los propulsores, $\Delta V_r, \Delta V_t, \Delta V_n$ **Teóricos:** Son los Diferenciales de velocidad teóricos en los tres ejes Radia, Tangencial y Normal, **Thruster Coeficient Teórico:** Este parámetro mide la eficiencia de los propulsores durante la ejecución de una maniobra, evaluando la efectividad de los pulsos generados por estos.

Elementos Orbitales antes de la Maniobra: Este conjunto de datos muestra todos los elementos orbitales que describen la forma y la orientación de la órbita con su respectivo Epoch.

- Semi eje Mayor (a)
- Excentricidad (e)
- Inclinación (i)
- Nodo ascendente (Ω)
- Argumento de Perigeo (ω)
- True Anomaly (v)

Total, Propellant Kg

Es el total de combustible disponible del satélite, inicialmente el tanque de combustible tiene una capacidad de 888 Kg este valor fue disminuyendo conforme se iba generando pulsos con los propulsores.

Elementos Orbitales después de la Maniobra

Este conjunto de datos muestra todos los elementos orbitales que describen la forma y la orientación de la órbita después de la maniobra donde puede observarse el efecto que los diferenciales de velocidad ocasionaron en la nueva órbita

ΔV_r , ΔV_t , ΔV_n Ranging

Son los Diferenciales de velocidad reales según los datos después de la maniobra. Si se excluye la eficiencia real en los propulsores o efectos de cross coupling este valor debería ser similar al valor teórico.

Thruster Coefficient Ranging

Este parámetro mide la eficiencia real de los propulsores durante la ejecución de la maniobra, evaluando la efectividad de los pulsos generados por estos.

Fuel Consumed

Es la cantidad de combustible que se usó en la maniobra, este valor debe restarse de la masa total de combustible para llevar un registro del combustible disponible, y este es el valor que se tratara de optimizar.

B. Análisis de uso de combustible por procedimiento de corrección orbital

La activación de propulsores puede realizarse de forma manual y de forma automática, en las maniobras de corrección orbital Oeste y Sur, se envía telecomandos desde el centro de control satelital en tierra especificando que propulsores deben activarse, la cantidad de pulsos y la duración de estos, por ello, es necesario llevar un registro manual del combustible utilizado en cada maniobra y contrastarlo con los datos de telemetría enviados por satélite.

De manera automática, el satélite también activa los propulsores a través del sistema **AOCS** (Attitude and Orbit Control System) para corregir perturbaciones y garantizar que el satélite mantenga un apuntamiento correcto hacia la Tierra.

En la Fig.1 se observa claramente la diferencia en el consumo de combustible entre las diversas maniobras y el subsistema **AOCS**. Este análisis es relevante, ya que el objetivo del

presente proyecto es optimizar el uso de combustible del satélite.

Según los datos, el consumo de combustible por parte del sistema **AOCS** representa el **17.31 %** del total. Sin embargo, dado que el **AOCS** actúa de forma autónoma para mantener el apuntamiento del satélite hacia la Tierra, su consumo no puede ser optimizado. Por otro lado, el consumo de combustible en la maniobra Oeste (**1.59 %**) es prácticamente despreciable en comparación con el **81.06 %** que corresponde a las maniobras Sur.

Este alto porcentaje de consumo en las maniobras sur indica que es el principal punto donde podrían implementarse estrategias de optimización. La diferencia significativa en el consumo tiene sentido, ya que las maniobras sur están destinadas a corregir la inclinación orbital, lo que implica generar cambios sustanciales en el plano de la órbita.




Fig. 1 Combustible Utilizado en el TKSAT-1 Hasta el 2023

C. Simulación de maniobras orbitales TKSAT-1 con simulador STK Astrogator

El Systems Tool Kit (STK) es una herramienta de simulación aeroespacial utilizada para modelar trayectorias y maniobras orbitales. Su módulo Astrogator permite personalizar parámetros críticos y considerar perturbaciones reales, como la presión solar y la gravedad de cuerpos celestes. En este proyecto, se utilizó Astrogator para simular y comparar las maniobras reales del TKSAT-1 con las optimizadas por Machine Learning, validando su impacto en la eficiencia de las maniobras.

D. Preparación y estructuración del conjunto de datos

Inicialmente, se identificarán los parámetros más relevantes necesarios para el análisis, estableciendo cuáles serán las variables de entrada y las variables de salida. La determinación de estas variables se basa en la lógica de la información disponible antes de realizar una maniobra que puede observarse en la tabla 1.

Tabla 1
Variables de Entrada y Salida del conjunto de datos

Variables de Entrada	Variables de Salida
Maneuver Date	ΔV_r Ranging
ΔV_r Teórico	ΔV_t Ranging
ΔV_t Teórico	ΔV_n Ranging
ΔV_n Teórico	Thruster Coeficient Ranging
Thruster Coeficient Teórico	Fuel Consumed
Elementos Orbitales	
Total Propellant	

A partir de las cabeceras del conjunto de datos de entrada y salida, se puede observar que los valores teóricos de los diferenciales de velocidad y la eficiencia de los propulsores están directamente relacionados con sus contrapartes en los datos de salida. Sin embargo, debido a la naturaleza no lineal y las incertidumbres inherentes al sistema, estos valores teóricos pueden diferir significativamente. Por esta razón, un modelo de Machine Learning es ideal para aprender y modelar estas desviaciones sobre todo porque se pudo optimizar el ΔV_n y el combustible consumido.

E. Entrenamiento de modelos de Machine Learning

Arquitectura RNN con LSTM

La arquitectura de la red neuronal recurrente (RNN) está diseñada para procesar datos secuenciales, permitiendo capturar relaciones temporales clave en los registros históricos de maniobras orbitales. La red está compuesta por dos capas LSTM con retorno de secuencias activado, seguidas de una tercera capa LSTM que extrae dependencias temporales adicionales. Posteriormente, una capa Dense con activación ReLU permite la identificación de patrones no lineales. La capa de salida tiene 5 neuronas que representan los diferenciales de velocidad (ΔV_r , ΔV_t , ΔV_n), el coeficiente del propulsor y el combustible consumido.

El modelo utiliza el optimizador Adam con una tasa de aprendizaje de 0.0003, lo que facilita un ajuste preciso de los pesos. La función de costo multivariable está diseñada para optimizar el consumo de combustible y el ΔV_n , que es clave en la maniobra Sur. Esta configuración permite reducir el consumo de combustible al tiempo que se mantiene el control del vector de inclinación, garantizando la estabilidad de la órbita.

$$Loss = \alpha Loss_{Fuel} + \beta Loss_{\Delta V_n}$$

Después de varios entrenamientos y ajustes en la arquitectura y la función de costos, se determinó que los valores óptimos de los coeficientes son: $\alpha=0.2$, $\beta=0.8$, la arquitectura puede observarse en la Fig.2

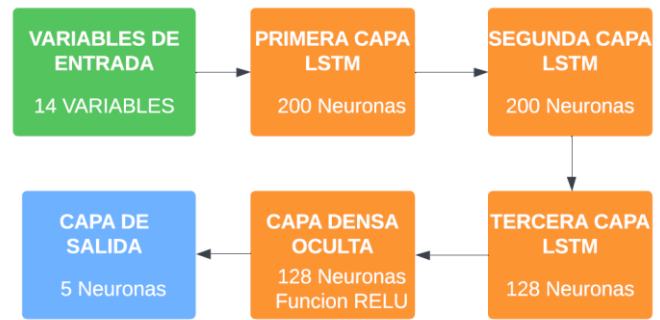


Fig. 2 Arquitectura RNN con LSTM

Arquitectura Random Forest

El modelo Random Forest se construye mediante la generación de 100 árboles de decisión, donde cada árbol se entrena con un subconjunto aleatorio de los datos (bootstrapping) y selecciona de forma aleatoria las características de entrada para dividir los nodos, evitando así el sobreajuste. Para este proyecto, se configuró una regresión multivariable con 5 salidas simultáneas: (ΔV_r , ΔV_t , ΔV_n), coeficiente de propulsores y consumo de combustible. La técnica de multi-output permite que cada árbol prediga estas variables de forma conjunta, mejorando la eficiencia y permitiendo la correlación entre las predicciones. Esta arquitectura se ilustra en la Fig.3



Fig. 3 Arquitectura Random Forest

F. Simulación en STK Astrogator con valores obtenidos del entrenamiento.

En la fase final del proyecto, una vez que se obtuvieron los modelos entrenados con métricas aceptables, se procedió a la simulación de maniobras Sur. Aunque durante las fases de entrenamiento y validación se utilizó el conjunto de datos correspondiente a las maniobras orbitales realizadas entre 2014 y 2023, en esta etapa se simularán las maniobras Sur del año 2024. El objetivo es evaluar el rendimiento práctico de los modelos en la optimización del consumo de combustible y verificar si efectivamente se puede lograr una mejora significativa en la eficiencia.

Para la simulación de las 10 primeras maniobras de corrección orbital Sur del año 2024, se crearon tres satélites en el simulador STK:

- TKSAT-1_Real: Este satélite utiliza los parámetros reales que se emplearon en las maniobras realizadas por el satélite TKSAT-1 durante el año 2024.
- TKSAT-1_Random Forest: Este satélite aplica los parámetros obtenidos mediante el modelo de entrenamiento basado en Random Forest.
- TKSAT-1_RNN: Este satélite utiliza los parámetros predichos por el modelo RNN para las mismas maniobras.

Para cada maniobra, se ingresaron nuevos valores de entrada no presentes en el entrenamiento, permitiendo que el modelo realice las predicciones correspondientes. El proceso se estructuró utilizando un bloque de secuencia para cada maniobra, lo que permite que, una vez finalizada una maniobra, el sistema pase automáticamente a la siguiente como se observa en la Fig.4, de este modo, se puede observar de forma continua el comportamiento y el efecto acumulativo de las maniobras a lo largo del año, especialmente sobre la inclinación de la órbita, que es el elemento orbital para corregir en las maniobras Sur.

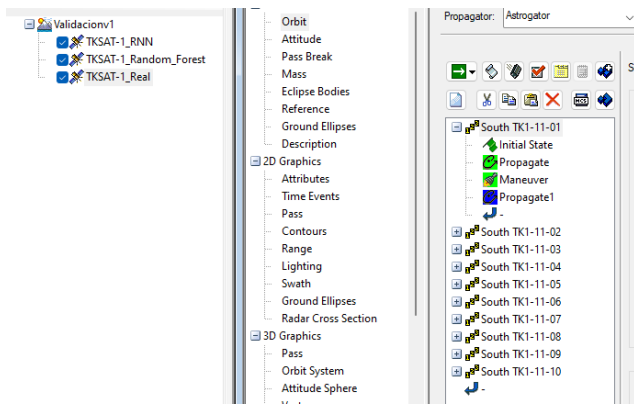


Fig. 4 Creación de tres satélites con sus respectivas secuencias

Este proceso se repite diez veces para cada uno de los tres satélites, resultando en un total de treinta maniobras Sur simuladas. Este enfoque permite evaluar, de forma gráfica y numérica, si los modelos de entrenamiento (Random Forest y RNN) lograron optimizar el uso de combustible en las maniobras

III. RESULTADOS

A. Resultado y comparación modelos RNN LSTM y Random Forest

El modelo RNN con LSTM prioriza la precisión en la predicción de ΔV_n , ya que esta variable es fundamental para la simulación en STK. Para lograrlo, se asignó un mayor peso a la predicción de ΔV_n ($\beta=0.8$) en la función de costos, lo que también impactó positivamente en la predicción del consumo de combustible (Fuel Consumed). Este enfoque permitió una optimización simultánea de ambas variables, destacando la relación directa entre la reducción de ΔV_n y la disminución en el uso de combustible.

Los resultados del entrenamiento muestran métricas de error bajas y aceptables, con un error relativo de 3.45 % para la predicción de ΔV_n y 4.58 % para el consumo de combustible.

Este bajo margen de error demuestra la capacidad del modelo para generar predicciones precisas y confiables. Además, se observa que los valores predichos de ΔV_n tienden a ser más pequeños, lo que se traduce en un menor consumo de combustible, evidenciando la coherencia y efectividad del modelo.

El modelo Random Forest mostró un buen desempeño en la predicción de las variables clave ΔV_n y el consumo de combustible (Fuel Consumed). Los resultados del entrenamiento evidencian métricas de error óptimas, destacando un error relativo del 4.33% para la predicción de ΔV_n y un 5.34% para el consumo de combustible. Estas métricas reflejan la capacidad del modelo para generar predicciones precisas y consistentes, lo que fortalece su utilidad para la optimización de maniobras orbitales.

Los valores predichos presentaron una alta correlación con los valores reales, lo que demuestra la eficacia del modelo para ajustarse al comportamiento del sistema.

Se realizó una evaluación comparativa de las métricas clave de los modelos RNN LSTM y Random Forest para las principales variables de salida: el consumo de combustible (Fuel Consumed) y el ΔV_n . Los resultados evidencian que el modelo Random Forest muestra un mejor desempeño en la predicción de ΔV_n , alcanzando un error relativo del 3.45%, en contraste con el 4.33% obtenido por la RNN LSTM. No obstante, en la predicción del combustible consumido, la RNN LSTM supera a Random Forest con un error relativo de 4.58%, frente al 5.34% de Random Forest. Cabe señalar que la diferencia entre ambos modelos en esta variable es mínima como se observa en la tabla 2.

Con base a estos resultados, se sugiere priorizar el uso del modelo RNN LSTM, especialmente para la predicción de ΔV_n , ya que esta variable es crítica para las simulaciones en el entorno STK. Sin embargo, para evaluar de forma integral su desempeño práctico, ambos modelos serán utilizados en las simulaciones de maniobras de corrección Sur, lo que permitirá obtener una mejor comprensión de sus capacidades y limitaciones en un entorno de simulación realista.

Tabla 2

Comparación de resultados RNN LSTM vs Random Forest

Modelo	Error Relativo (Fuel Consumed)	Error Relativo (ΔV_n)
Random Forest	5.34%	4.33%
RNN LSTM	4.58%	3.45%

B. Simulación de los modelos entrenados y el real en STK

Posterior a la simulación de las diez maniobras en los tres satélites configurados usando los parámetros correspondientes a los valores reales y predichos por los modelos de Random Forest y RNN LSTM se obtuvieron los siguientes resultados:

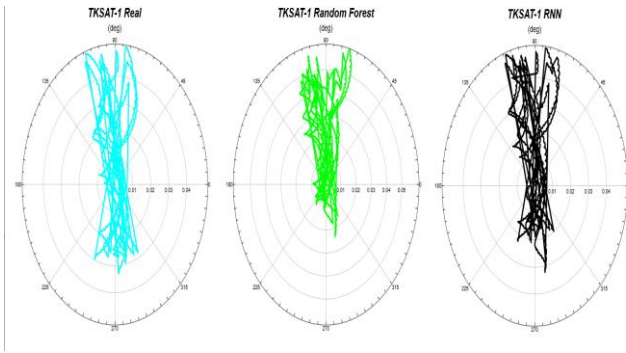


Fig. 5 Vector de inclinación de los tres satélites

En la Fig.5 se puede observar el comportamiento de los tres satélites simulados. Los resultados muestran que los tres modelos logran mantener el control del vector de inclinación, garantizando que, siempre que la gráfica alcance los límites establecidos y regrese al origen de la gráfica. Esto asegura que la órbita se mantenga paralela al plano ecuatorial.

Es importante destacar que, aunque los modelos de predicción cumplen su objetivo, el modelo basado en Random Forest sobrepasa el límite de 0.05 en ciertas ocasiones, mientras que tanto el modelo real como el modelo basado en RNN se mantienen dentro del margen esperado.

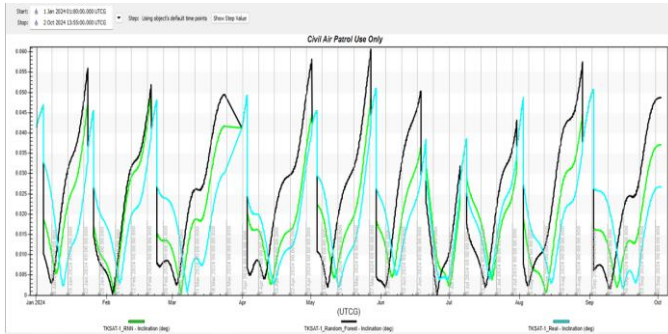


Fig. 6 Comportamiento de la inclinación con respecto al tiempo

En la Fig 6. Se observa que el modelo real se mantiene consistentemente dentro de los límites establecidos, con un mayor tiempo de convergencia al punto cero en comparación con los otros dos modelos. Esto indica que la estrategia orbital del TKSAT-1 mantiene un control estable de la inclinación, evitando que las maniobras sean más frecuentes. Este comportamiento refleja una prioridad en la estabilidad de la órbita a largo plazo.

Por otro lado, los modelos RNN y Random Forest muestran un menor tiempo de convergencia al punto cero, lo que es coherente con el diseño de los modelos. Al optimizar el diferencial de velocidad (ΔV_n) y el consumo de combustible, los valores predichos tienden a ser más pequeños, resultando en días de control más cortos.

En cuanto a los límites establecidos para la inclinación, el modelo Random Forest muestra un comportamiento que ocasionalmente supera el límite de 0.05 grados, mientras que el modelo RNN logra mantenerse dentro del margen establecido. Esto refuerza la idea de que, el modelo RNN ofrece una mayor estabilidad en el control de la inclinación orbital.

Finalmente, se analizaron los resultados del combustible consumido por la estrategia actual del TKSAT-1 y los modelos optimizados basados en RNN LSTM y Random Forest.

El análisis revela que la estrategia actual de control robusto del TKSAT-1 presenta el mayor consumo de combustible, totalizando 33.989 kg en 10 maniobras Sur. En contraste, el modelo RNN LSTM reduce significativamente este consumo a 30.824 kg, logrando una optimización de aproximadamente 3.165 kg. Este modelo destaca por mantener los límites de control de la inclinación orbital, garantizando la estabilidad de la órbita a lo largo del tiempo.

El modelo Random Forest, por su parte, presenta la mayor reducción de consumo de combustible, alcanzando un total de 26.084 kg para las mismas 10 maniobras. Esto representa un ahorro aproximado de 7.905 kg en comparación con la estrategia actual. Sin embargo, se identificó que este modelo supera ocasionalmente el límite de inclinación de 0.05 grados, lo que podría afectar la estabilidad de la órbita. Esta observación resalta la necesidad de un equilibrio entre la eficiencia en el consumo de combustible y el control de la inclinación orbital.

C. Análisis ahorro de combustible y prolongación vida útil del satélite

Una vez obtenidos los resultados de optimización de los modelos entrenados y el tiempo de vida estimado del TKSAT-1, es posible calcular el promedio de combustible utilizado por maniobra Sur tanto con la estrategia de corrección actual como con los parámetros optimizados por los modelos RNN-LSTM y Random Forest. Además, se puede estimar el costo asociado a cada kilogramo de combustible ahorrado, proporcionando un análisis más detallado de los beneficios económicos y operativos de la optimización como se observa en la Tabla 3.

Tabla 3
Proyección de Consumo y Ahorro de Combustible en Maniobras Sur del TKSAT-1 con Modelos Optimizados

Modelo	Promedio de Combustible por mes en maniobras Sur (Kg)	Meses restantes de vida útil del satélite (a partir de inicios del 2025)	Proyección de combustible utilizado en maniobra Sur hasta el fin de vida	Cantidad de Combustible Ahorrado (Kg)
TKSAT1-Real	3.37	56.60	190.74	0.00
TKSAT1-RNN	3.08	56.60	174.46	16.28
TKSAT1-Random Forest	2.61	56.60	147.64	43.11

La proyección realizada indica que, de mantenerse la estrategia actual de control, el satélite podría operar de manera continua durante aproximadamente 5.7 años con un promedio de gasto de combustible de 4.16 Kg/mes, alcanzando su límite de combustible a finales de agosto de 2029. Sin embargo, si se implementan las estrategias de optimización propuestas por los modelos de Machine Learning, la vida útil del satélite podría extenderse aún más, reduciendo el consumo de combustible en las maniobras Sur como se observa en la tabla 4.

Tabla 4
Proyección Extensión del Tiempo de Vida del Satélite
TKSAT-1 mediante Modelos Optimizados

Modelo	Cantidad de Combustible Ahorrado (Kg)	Promedio de Combustible usado por mes (Kg)	Meses extras del tiempo de vida del satélite
TKSAT1-RNN	16.28	4.16	3.91
TKSAT1-Random Forest	43.11	4.16	10.36

Estas proyecciones destacan la importancia de la optimización de maniobras, ya que la eficiencia en el uso de combustible se traduce en una mayor operatividad del satélite. La implementación de esta metodología permitiría prolongar la vida útil del TKSAT-1, garantizando su funcionalidad durante un periodo más prolongado y maximizando su aprovechamiento operacional.

IV. CONCLUSIONES

El uso de modelos de Machine Learning permitió una optimización significativa en los parámetros de las maniobras de corrección Sur, logrando una notable reducción en el consumo de combustible del satélite TKSAT-1.

El modelo basado en RNN LSTM logró reducir el consumo de combustible en un 8.82 % manteniéndose dentro de los límites de control del ángulo de inclinación de la órbita. Por otro lado, el modelo Random Forest alcanzó una reducción superior del 23.53 % sin embargo, su comportamiento excede los límites de control del ángulo de inclinación, lo que podría afectar la estabilidad de la órbita a largo plazo.

Ambos modelos cumplen con el objetivo principal de optimizar el uso de combustible en la maniobra Sur. No obstante, se recomienda optar por el modelo RNN LSTM, ya que este ofrece un equilibrio adecuado entre la eficiencia en el consumo de combustible y la estabilidad orbital.

La implementación de los parámetros optimizados propuestos por el modelo RNN permitiría extender la vida útil del satélite en **4 meses** adicionales. En el caso del modelo Random Forest, la extensión alcanzaría hasta **10 meses** adicionales, aunque este modelo requiere una evaluación más profunda debido a su posible impacto en la estabilidad orbital.

Este proyecto demuestra que la implementación de técnicas de Machine Learning en la optimización de los recursos de satélites geoestacionarios no solo es factible, sino que también tiene un impacto significativo en la sostenibilidad operativa. La optimización del uso de combustible permite extender la vida útil del satélite, garantizando su funcionalidad por un periodo de tiempo más prolongado y maximizando su aprovechamiento operacional.

El proyecto fortalece la capacidad tecnológica y estratégica de la Agencia Boliviana Espacial, contribuyendo al desarrollo

tecnológico del país y abriendo la posibilidad de aplicar estas técnicas en futuros proyectos de optimización de recursos para satélites de telecomunicaciones.

APÉNDICES

https://github.com/Rodrigo-ABE/TKSAT-1_Optimization_Project.git


Repositorio del proyecto en Git-Hub

AGRADECIMIENTOS

Agradezco a la Agencia Boliviana Espacial por su valiosa colaboración y por facilitar el acceso a la información y los datos históricos del satélite boliviano TKSAT-1, los cuales fueron fundamentales para la realización de este proyecto.

Referencias

- [1] Y. Liu, Y. Zhao, C. Tan, H. Liu, and Y. Liu, "Economic value analysis of on-orbit servicing for geosynchronous communication satellites," *Acta Astronautica*, vol. 180, pp. 176–188, 2021.
- [2] L. Perko, *Differential Equations and Dynamical Systems*, vol. 7. Springer-Verlag, 1991.
- [3] S. A. Botta, "Clase 11: Perturbaciones Orbitales." Universidad Nacional de La Plata, 2023.
- [4] Singh_Sahjendra_N_and_Yim_Woosoon, "Feedback linearization and solar pressure satellite attitude control," *IEEE Transactions on Aerospace and Electronic Systems*, vol. 32, no. 2, pp. 732–741, 1996.
- [5] SoopE.M., *Handbook of Geostationary Orbits*. Dordrecht: Springer, 1994.
- [6] SeppHochreiter and JürgenSchmidhuber, "LongShort-TermMemory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [7] L. Breiman, "RandomForests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.



Ing. Rodrigo Montaña Villarroel, titulado de la carrera de Ingeniería Mecatrónica de la Universidad Católica Boliviana San Pablo, es postulante al grado de Maestría en Sistemas Mecatrónicos. Actualmente, se desempeña como Ingeniero en el Centro de Operaciones de la Agencia Boliviana Espacial, donde contribuye con su experiencia en la gestión y control de sistemas satelitales.